



Московский авиационный институт (национальный исследовательский университет)

Институт №8 «Компьютерные науки и прикладная математика»

Кафедра №806 «Вычислительная математика и программирование»

**Выпускная квалификационная работа бакалавра на тему:**  
**Использование обучения с подкреплением ИИ в**  
**позиционных играх**

**Студент группы М8О-412Б-22:** Андрюшин Лев Дмитриевич

**Научный руководитель:** старший преподаватель ОЦ 8 МАИ Аносова Наталья Павловна

**Консультант:** Крылов Сергей Сергеевич, к.ф.-м.н, доцент, директор института № 8

Москва 2026

# Актуальность темы

- Обучение с подкреплением является одним из наиболее перспективных направлений искусственного интеллекта.
- Игровые среды позволяют эффективно тестировать алгоритмы самостоятельного принятия решений.
- Полученные результаты могут быть использованы при разработке интеллектуальных систем различного назначения.


# Цель работы

Разработка и реализация системы искусственного интеллекта на основе методов обучения с подкреплением для позиционной пошаговой дуэльной стратегии с последующей интеграцией в игровой программный продукт.


# Задачи работы

- формализация правил разработанной игровой системы;
- проведение анализа предметной области и существующих подходов к разработке игровых интеллектуальных систем;
- разработка архитектуры системы искусственного интеллекта и итогового проекта;
- реализация программных компонентов игровой системы и среды обучения модели;
- обучение и тестирование модели;
- интеграция разработанного решения в игровой продукт.


# Описание правил разработанной игры



Победа черных  
закрытием квадрата



Игра продолжается, оба  
соперника закрыли по  
одной области



Победы черных,  
закрытием  
треугольника на  
границе поля

# Анализ алгоритмов принятия решений к разработанной игре

Количество возможных игровых конфигураций:

$$5^{81} \approx 4.135 \times 10^{56}$$

Количество доступных действий каждый ход:

$82 - i$ , где  $i$  – номер хода.


Варианты алгоритмов:

1. Классическое дерево решений
2. Модернизации дерева решений
3. Обучение с подкреплением

# Обучение с подкреплением

Обучение с подкреплением – метод машинного обучения, при котором агент обучается стратегии поведения через взаимодействие со средой и получение вознаграждения или штрафов за совершаемые действия:

- Агент получает информацию о текущем состоянии игрового поля
- На основе состояния выбирается действие (ход)
- После выполнения действия агент получает награду
- Цель обучения – максимизация суммарного вознаграждения и формирование эффективной стратегии игры





# Выбор алгоритма обучения

- **DQN (Deep Q-Network)**
  - Value-based алгоритм обучения с подкреплением
  - Обучает Q-функцию, оценивающую ожидаемую награду действий
  - Политика формируется выбором действия с наибольшим Q-значением
- **PPO (Proximal Policy Optimization)**
  - Policy-based алгоритм обучения с подкреплением
  - Непосредственно обучает стратегию выбора действий
  - Обновляет параметры политики на основе преимущества (advantage) и собранного опыта
- **AlphaZero**
  - Комбинирует нейронную сеть и поиск по дереву Монте-Карло (MCTS)
  - Нейронная сеть оценивает состояние и вероятности действий
  - Поиск используется для выбора наиболее перспективного хода



# Причины отказа от DQN

- Модель не демонстрировала улучшения качества игры;
- Изменение гиперпараметров не приводило к заметному прогрессу;
- Изменение функции вознаграждения не дало ожидаемого эффекта;
- Добавление новых каналов наблюдения тоже не дало никаких результатов;
- Дальнейшее обучение не выглядело перспективным




# Причины отказа от AlphaZero

- Существенное усложнение архитектуры разрабатываемой системы.
- Значительное увеличение вычислительных затрат на обучение.
- Большой объём дополнительной реализации и экспериментальной настройки.
- Высокий риск не завершить разработку в рамках доступного времени.

# Причины выбора PPO

- Стабильное обновление стратегии без резких изменений поведения;
- Эффективная работа с долгосрочными последствиями игровых решений;
- Демонстрация устойчивого роста качества игры в ходе обучени.




# Алгоритм PPO (Proximal Policy Optimization)



# Архитектура проекта



# Архитектура обучения



# Описание процесса обучения

В процессе обучения нейронная сеть взаимодействует с игровой средой, последовательно анализируя состояния игрового поля и выбирая действия на основе текущей стратегии. На каждом шаге нейронная сеть получает текущее состояние игрового поля в виде тензора размерности  $9 \times 9 \times 18$  и формировала вероятности возможных действий. Пространство действий состоит из 162 возможных ходов.

Для исключения недопустимых действий использовался механизм action masking, запрещающий выбор невозможных ходов до этапа принятия решения моделью.

# Каналы

- Каналы 0–4 содержат информацию о пустых клетках и расположении фигур обоих игроков;
- Каналы 5–11 описывают локальное окружение клетки, включая количество соседних фигур, граничных элементов, степень заполненности области, а также распределение фигур различных типов среди соседних клеток;
- Каналы 12–13 содержат эвристическую оценку потенциала формирования замкнутых областей для различных типов фигур;
- Каналы 15-16 показывают клетки, в которые, если поставить квадрат или треугольник, можно «закрыть область»;
- Канал 14 показывают оставшееся до конца количество ходов;
- Канал 17 показывает является ли текущий игрок агентом или нет;



# Турнирная система отбора соперников

Раз в фиксированное число эпизодов проводится турнир.

## **Участники турнира:**

- 6 лучших моделей по рейтингу Elo с предыдущего турнира;
- текущая обучаемая модель;
- до 4 проблемных моделей, против которых обучаемая модель в прошлом турнире, показала минимальный процент побед;
- случайные модели из архива для заполнения оставшихся мест.

## **По результатам турнира формируется новый пул соперников для обучения:**

- 6 лучших моделей по Elo;
- 4 наиболее проблемных соперника;
- случайные архивные модели.

# Функция награды


## Базовая награда:

- Победа: +1
- Поражение: от -1 до -3.5
- Ничья: 0
- Небольшой штраф каждый ход



## Локальная награда:

- Поощрение формирования собственных областей
- Поощрение разрушения областей соперника
- Штраф за опасные и заведомо невыгодные ходы
- Штраф за упускание победы и разрушение своих областей


# Результаты финального тестирования модели против прошлых версий



# Интеграция в готовый проект



Unity



ONNX  
RUNTIME

# *Ручное тестирование*

| Тип проверки              | Период партии | Количество попыток | Успешные случаи | Неуспешные случаи | Успешность (%) |
|---------------------------|---------------|--------------------|-----------------|-------------------|----------------|
| Победа в 1 ход            | Все           | 50                 | 35              | 15                | 70.0           |
| Победа в 1 ход            | До 10 хода    | 38                 | 30              | 8                 | 78.9           |
| Победа в 1 ход            | После 10 хода | 12                 | 5               | 7                 | 41.7           |
| Блокировка угрозы (1 ход) | Все           | 88                 | 65              | 23                | 73.9           |
| Блокировка угрозы (1 ход) | До 10 хода    | 70                 | 59              | 11                | 84.3           |
| Блокировка угрозы (1 ход) | После 10 хода | 18                 | 6               | 12                | 33.3           |

# Заключение

**Цель работы достигнута** — разработана система ИИ для позиционной игры на основе обучения с подкреплением (PPO).

## **В ходе работы:**

- Формализованы правила игровой среды
- Проведен анализ предметной области и существующих подходов к разработке игровых интеллектуальных систем
- Разработана архитектура системы искусственного интеллекта и итогового проекта
- Реализованы программные компоненты игровой системы и среды обучения модели
- Модель была обучена и протестирована
- Модель была интегрирована в итоговый проект

## **Результат:**

- Модель формирует базовую стратегию игры
- Учитывает тактику и локальные ситуации
- Демонстрирует работоспособность подхода RL

# Перспективы развития

- Увеличение времени обучения
- Дальнейшее улучшение функции награды
- Расширение правил и типов фигур
- Переход на AlphaZero

# QR-код репозитория с исходным кодом

